Regresión Lineal

1. Definición

Modelo estadístico empleado para aproximar la relación de dependencia entre una variable dependiente (dígase Y) con n variables independientes (dígase X) bajo un término aleatorio **ε**, de forma que las variables independientes pertenecen a los reales.

Este método busca predecir la existencia (o no) de un comportamiento predictivo dependiendo del nivel de correlación entre las variables estudiadas. El resultado es una función que se expresa como una línea cuya inclinación esta dominada por los datos.

2. Notas

Para emplear este método hace falta dar algunas pautas al respecto:

- En su equivalente digital el modelo pertenece al conjunto de algoritmos de aprendizaje supervisado. Ya que se entrena con datos etiquetados y se busca que la recta producida pueda predecir valores continuos.
- No es posible trazar una línea recta que pase por todos los puntos de un gráfico, por lo tanto, sólo se determina la ubicación óptima de la línea a través de la regresión lineal.
- Algunos puntos seguirán distanciados de la recta, pero esta distancia debe ser mínima. Esta distancia mínima de la recta a cada puno se denomina ***función de pérdida*.**

3. Definición matemática

Matemáticamente el modelo estadístico busca ***aproximar*** una función lineal, de modo que esta pueda describir lo mejor posible la relación entre variables observadas. Formalmente se puede definir como:

$$y = X\beta + \varepsilon$$

Donde y es es el vector de valores observados, X la matriz de variables independientes, β el vector de parámetros desconocidos y ε el error. El objetivo principal es estimar β de tal manera que el modelo reproduzca lo mejor posible los datos observados (minimizar la distancia entre lo observado y lo predicho).

4. Funcionamiento

1. Se plantea el problema, identificando claramente qué variable se desea explicar (dependiente) y cuáles podrían influir en ella (independientes).
2. Se recolectan y preparan los datos, limpiando de valores faltantes, detectando posibles errores y, en algunos casos, transformando variables para que la relación sea aproximadamente lineal.
3. Se estiman los coeficientes $\boldsymbol{\beta}$ usando el criterio de mínimos cuadrados, equivale a encontrar la recta (o hiperplano) que mejor se ajusta a los datos.
4. Una vez ajustado, se procede a evaluar el modelo: se analizan métricas como el error, el coeficiente de determinación, así como los residuos.
5. Se realiza la interpretación de los coeficientes, entendiendo cómo cada variable independiente afecta a la dependiente.
6. Si el modelo tiene un buen desempeño, puede utilizarse para estimar valores futuros o comprender relaciones entre variables.

5. Tipos de Regresión

Particularmente todos los modelos de regresión lineal usan las mismas variables:

- **Y =** Representa la variable dependiente (o el efecto producido de manipular la variable independiente).
- **X =** Dependiendo del tipo de regresión lineal puede abarcar una o múltiples variables, pero siempre representando la variable independiente, que es nuestro factor descriptivo o explicativo que se relaciona con la varianza.
- **β0 =** Indica el valor base cuando no hay influencia de la variable independiente (valor de Y cuando X es cero -punto de intersección-).
- **β1 =** Representa el cambio que se espera en la variable respuesta por cada unidad en la variable explicativa (cambio promedio en Y por cada unidad aumentada en X; o, en otras palabras, la pendiente de la recta).
- **ε =** Épsilon representa nuestra función de perdida, o limite para determinar la mejor posición para nuestra línea.

Regresión Lineal Simple.

Este modelo asume que el cambio en la variable dependiente (Y) puede explicarse linealmente a partir de una única causa (X).

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Limitaciones:

Difícilmente puede capturar la complejidad de fenómenos reales, por igual es sensible a valores atípicos y depende fuertemente del supuesto de linealidad (que las variables predictoras tengan relación lineal con la variable resultado).

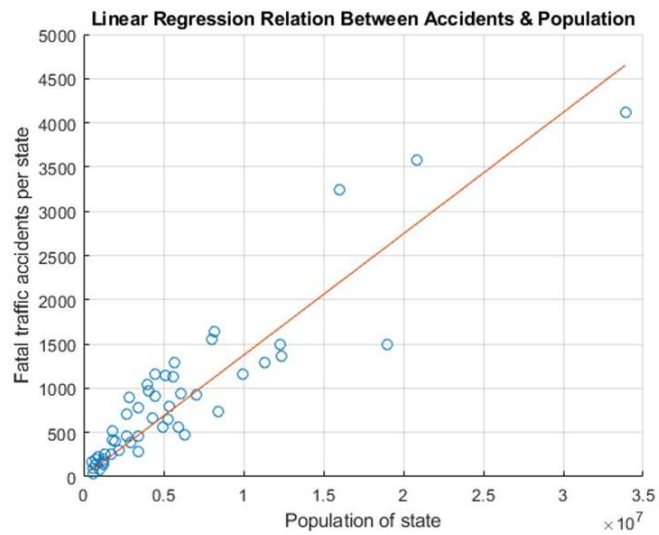

Regresión Lineal Múltiple.

Esta modelo amplia la capacidad del modelo considerando que el fenómeno se explica a través del análisis de múltiples variables predictoras (X_i) en lugar de solo una (X).

En este modelo cada coeficiente mide el efecto parcial de una variable sobre el resultado mientras el resto de las variables se mantienen constantes.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon$$

Limitaciones:

Existe la probabilidad de que el modelo pueda alucinar o no encontrar el efecto individual de las variables sobre a variable dependiente. Gracias a esto los coeficientes pueden volverse inestables o perder significancia estadística.

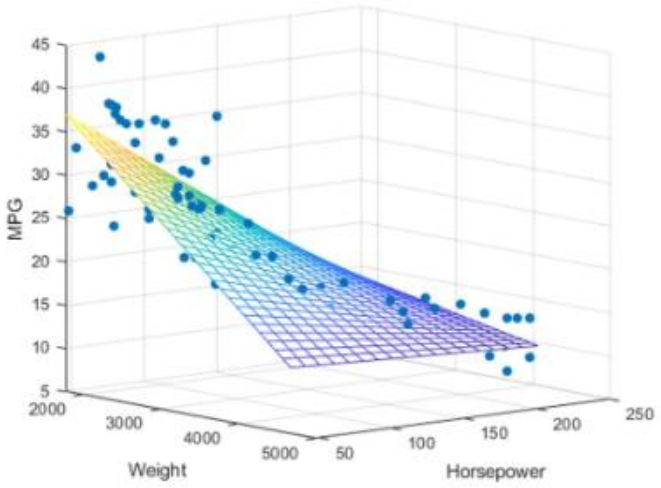

Regresión Lineal Multivariable.

Este tipo de regresión considera múltiples variables dependientes al mismo tiempo, por lo que, en lugar de enfocarse en una única salida, este modelo analiza varios resultados que podrían estar relacionados entre sí a través de estructuras matriciales.

El resultado es una matriz Y que contiene varias respuestas, las cuales capturan la posible correlación entre variables dependientes (ya no solo entre variables independientes y dependientes).

$$Y_1 = \beta_{01} + \beta_{11} X_1 + \epsilon_1$$

$$Y_2 = \beta_{02} + \beta_{12} X_1 + \epsilon_2$$

Limitaciones:

A pesar de que se aprovecha la información compartida entre salidas, el número de variables aumenta significativamente la complejidad del problema y generando una respuesta menos intuitiva.

$$\begin{pmatrix} Y_1 \\ Y_2 \end{pmatrix} = \begin{pmatrix} \beta_{01} & \beta_{11} \\ \beta_{02} & \beta_{12} \end{pmatrix} \begin{pmatrix} 1 \\ X_1 \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \end{pmatrix}$$

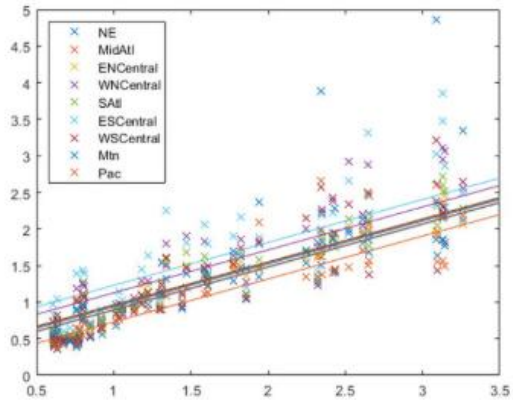

Regresión Lineal Múltiple Multivariable.

Este modelo combina múltiples variables independientes con múltiples variables dependientes, por lo que explota desde muchos puntos, como todas las variables en juego pueden explicar una respuesta, a su vez que esa respuesta puede manipularse para explicarse a si misma.

Limitaciones:

Es el modelo más potente dentro del marco lineal, por lo que también es el más exigente en términos de datos, capacidad computacional y rigor en la validación, ya que aumenta el riesgo de sobreajuste y dificulta la interpretación de los resultados

$$\begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1q} \\ 1 & x_{21} & x_{22} & \cdots & x_{2q} \\ 1 & x_{31} & x_{32} & \cdots & x_{3q} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nq} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_q \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \epsilon_3 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

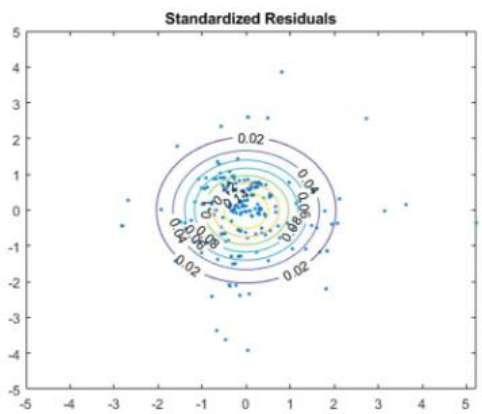

Imágenes extraídas de:

MathWorks. (s. f.). *Linear regression*. https://la.mathworks.com/discovery/linear-regression.html